

地铁 AFC 闸机故障工单预测项目

对话整理报告与技术路线建议

整理对象	基于本轮关于 Polars、地铁 AFC 故障工单预测、复发风险与巡检优先级的对话内容
数据文件	afc 非首次故障-L01 线(2).xlsx
核心方向	工单驱动的 AFC 闸机复发风险预测与智能巡检 Agent
整理日期	2026 年 4 月 30 日

定位建议：不主打“精确预测第几天必坏”，而主打“风险窗口 + 巡检优先级 + 故障现象倾向 + Agent 维修建议”。

一、整理结论摘要

本轮对话围绕“只有地铁现场故障工单、没有传感器数据时，能否做 AFC 闸机故障预测”展开。综合数据形态、建模可行性、工程价值、论文支撑和市场产品形态，最稳妥、最有项目价值的路线是：工单驱动的 AFC 闸机复发风险预测与智能巡检 Agent。

核心判断：当前数据可以用于预测“未来一段时间内再次产生故障工单的风险”，也可以用于输出高风险设备排序、可能故障现象和维修建议；但不适合作为核心目标去宣称“精确预测某台闸机第几天必然发生物理故障”或“准确判断真实根因”。

讨论问题	整理后的结论
是否能预测	能，但应预测复发风险、风险窗口和巡检优先级，而不是传感器级实时健康状态。
为什么不能主打精确日期	工单时间受发现、报修、派工、维修记录习惯影响，不等于设备真实物理故障发生时刻。
为什么不能直接预测真实原因	description 多为故障现象，如“卡票、暂停服务、死机”，缺少维修措施、换件记录和诊断结论。
最优路线	Polars 数据清洗 + 工单文本标准化 + 生存分析/LightGBM 风险模型 + Agent 维修建议。
项目价值	帮助运维人员优先检查高风险闸机、提前准备备件、减少被动报修和二次上门。

二、数据条件与可用信息

上传文件为“afc 非首次故障-L01 线(2).xlsx”，其本质不是传感器时序数据，而是一张“故障事件工单表”。也就是说，每一行代表某台闸机在某个时间被记录了一次故障或报修。

字段	含义	建模价值
assetnum	闸机/设备编号	构建设备级历史故障序列，是最核心字段。
station_name	车站名称	构造车站风险、车站聚集性、运维区域特征。
cust_linenum	线路号	当前文件为 L01，可用于后续多线路扩展。
current_faildate	本次故障/工单时间	用于计算复发间隔、时间窗口标签和训练/测试切分。
prev_faildate	上一次故障时间	可辅助计算两次故障之间的时间间隔。
total_failure_count	总故障次数	需谨慎使用，若为全周期统计可能存在未来信息泄露。
description	故障描述	可抽取“卡票、暂停服务、死机”等标准故障现象。
cust_brand	品牌	可作为设备属性特征。
pre_type / pre_value	预测或预警相关字段	pre_type 基本为空，pre_value 缺失多，不宜作为核心标签。

对该文件的初步统计如下。该统计用于说明数据规模与数据约束，后续正式建模时仍应重新进行清洗、去重和特征校验。

统计项	结果
工单记录数	19994 条
设备数量	480 台
车站数量	16 个
线路	L01
时间范围	2014-07-26 至 2025-11-26
工单类型	CM
子系统	AFCAGM
主要品牌	三星 18914 条；新科 592 条；NULL 488 条
pre_type	全部为空
pre_value	缺失 15647 条，非空 4347 条

三、为什么当前数据不适合“精确预测原因”

当前 description 字段表达的主要是“故障现象”，而不是工程意义上的“故障根因”。例如“卡票”说明乘客侧或票卡通道出现卡滞现象，“暂停服务”说明设备进入不可服务状态，“死机”说明软件或控制系统表现异常，但它们不能直接证明真实根因是读写器、票卡通道、电源、主控板、通信模块还是维修质量问题。

工单描述示例	更接近的含义	能否直接作为根因
卡票	故障现象/乘客侧表现	不能。可能涉及票卡通道、回收机构、传感器、异物等。
暂停服务	设备状态	不能。可能由机械、电源、通信、软件等多种原因触发。
死机	设备表现	不能。可能涉及软件、主控、供电、通信等。
验票不放行	交易/通行异常表现	不能。可能涉及读写器、扇门机构、控制逻辑等。
通信中断	较接近原因但仍需核实	只能作为可能方向，仍需日志或维修记录确认。

因此，文档和答辩中建议使用“可能故障原因推断”“检查方向建议”“故障现象倾向预测”，而不要直接写成“准确预测真实根因”。若想真正提升原因预测能力，需补充维修措施、更换部件、维修人员诊断结论、停机时长、客流量/交易量、闸门开合次数、设备安装年限等字段。

四、为什么不建议主打“第几天精确概率”

工单时间不是传感器采样时间。传感器采样通常是固定频率，例如每秒、每分钟或每小时记录一次；而工单数据是事件驱动数据，只有当异常被发现、上报并进入维修流程时才会形成记录。

因此，表中的 `current_faildate` 更准确地说是“工单记录时间或报修相关时间”，不一定等于设备真实物理故障发生的精确时间。它可能受到以下因素影响：

影响因素	说明	对精确日期预测的影响
发现滞后	偶发卡票、不能分析车票等问题可能先被临时处理，严重后才报修。	真实异常可能早于工单日期。
人工报修流程	不同车站、班次和站务人员的报修习惯不同。	同样故障在不同车站的记录时间可能不一致。
维修安排	临时复位、彻底维修、换件与否会显著影响下一次工单时间。	模型难以区分“设备本身易坏”还是“上次没修彻底”。
工单合并与重复	同一故障可能重复登记，也可能多个现象合并为一张工单。	会扭曲复发间隔分布。
补录和记录习惯	部分工单可能不是实时录入，而是后期补录或统一记录。	日期噪声会被模型误学为设备规律。

所以，如果系统直接输出“第 17 天一定复发”或“第 23 天故障概率最高”，看起来高级，但很容易被质疑。更稳妥的表达是：未来 7 天、30 天、90 天内复发风险是多少，以及高风险窗口大致集中在哪一段时间。

五、复发风险与巡检优先级的真实含义

5.1 复发风险是什么

复发风险不是说设备一定会坏，而是估计“从当前时刻起，未来某个时间窗口内再次产生故障工单的概率”。

风险指标	含义	适用决策
未来 7 天复发风险	短期内再次报修的概率	本周是否立即巡检或重点盯防。
未来 30 天复发风险	近期再次报修的概率	月度维保计划、近期派单计划。
未来 90 天复发风险	中期再次报修的概率	季度备件计划、重点车站治理。
高风险窗口	风险快速上升的大致时间段	确定更合适的巡检时间，而非机械等待故障发生。

5.2 巡检优先级是什么

巡检优先级指的是：在维修人员、时间和备件有限的情况下，系统帮助运维团队决定“先检查哪台设备、哪个车站、哪类部件”。它不是单纯展示概率，而是将模型输出转化为可执行的维修顺序。

排名	设备/车站	风险信号	建议巡检方向
1	30 天风险高且近 60 天多次复发的闸机	短期复发概率高、历史间隔短	优先安排现场巡检。
2	同一车站多台设备集中出现类似故障	车站级聚集性明显	检查车站环境、票卡流转、网络或供电条件。
3	连续出现“卡票/不接收单程票”的设备	票卡通道类现象持续出现	检查票卡通道、票箱、传感器、异物。
4	连续出现“暂停服务/死机/通信中断”的设备	系统或通信类现象持续出现	检查主控、网络、电源、系统日志。

因此，“预测未来 7/30/90 天复发风险”并不低级。低价值的是只显示一个概率；高价值的是把概率转化为高风险清单、巡检排序、备件建议和维修解释。

六、推荐的最优技术路线

如果只能选择一条最优路线，建议选择：工单驱动的 AFC 闸机复发风险预测与智能巡检 Agent。该路线既符合当前数据条件，也有论文和市场产品支撑。

阶段	模块	主要任务	输出
1	数据清洗	读取 Excel，统一日期格式，去除重复/异常工单，按设备排序。	干净的设备级故障事件序列。
2	文本标准化	从 description 中提取“卡票、暂停服务、死机”等标准故障现象。	故障现象标签。
3	特征工程	构造历史故障次数、最近间隔、近 30/90/180 天故障次数、车站/品牌/时间特征。	设备-时点级训练样本。
4	复发风险建模	使用离散时间生存分析、LightGBM、CatBoost 或逻辑回归预测 7/30/90 天风险。	复发风险概率和风险等级。
5	故障现象预测	基于历史现象序列和文本特征预测下次可能现象。	可能故障类型。
6	巡检排序	综合风险概率、故障严重程度、复发频率、车站影响生成优先级。	高风险闸机 Top N 清单。
7	Agent 建议生成	结合模型输出、历史相似案例和维修规则生成解释与建议。	可读、可执行的维修建议。

技术栈建议：Polars 用于高效清洗和特征工程；Scikit-learn / LightGBM / CatBoost 用于风险建模；lifelines 或 scikit-survival 用于生存分析；FastAPI 提供后端接口；Streamlit 或前端页面实现看板；LangChain/RAG/Agent 负责把模型结果和规则库转化为维修建议。

七、建模目标的正确表达

项目表述应避免夸大。下面给出“不建议写法”和“建议写法”的对照。

不建议写法	问题	建议写法
系统可以精确预测闸机第几天发生故障。	工单日期有噪声，且缺少传感器状态数据。	系统预测未来不同时间窗口内再次产生故障工单的概率。
系统可以准确判断故障根因。	description 多为现象，不是维修诊断。	系统给出可能故障现象和优先检查方向。
模型输出一个 30 天风险概率。	单个概率难以指导运维。	输出 7/30/90 天风险、风险等级、巡检优先级和维修建议。
预测性维护完全替代人工经验。	现场维修仍需人工确认。	系统辅助运维人员从被动报修转向主动巡检。

推荐项目定位语句：本项目面向地铁 AFC 闸机缺少实时传感器数据的实际场景，利用历史故障工单中的设备编号、车站、故障时间、上次故障时间、故障描述和品牌信息，构建设备级故障序列；通过文本挖掘、时间间隔建模和机器学习风险模型，预测闸机在未来 7 天、30 天和 90 天内的复发风险，并结合智能 Agent 生成可解释的巡检优先级与维修建议。

八、论文与市场支撑

8.1 论文支撑

已有研究表明，在缺少实时传感器数据时，仍可以利用历史维护记录、工单时间和资产属性进行预测性维护建模。Moat 与 Coleman 研究了 non-sensored assets 的预测性维护，使用 Kaplan-Meier、Cox 比例风险模型、AFT 等生存分析方法，这为“无传感器设备的复发风险建模”提供了直接依据 [1]。

维修工单文本挖掘也有成熟研究基础。Gunay 等人的研究通过文本挖掘分析建筑维护工单中的部件故障频率，说明非结构化工单描述可以被清洗、归类并用于可靠性分析 [2]。此外，工业维修记录中提取故障时间数据、从维护记录中识别故障事件等研究，也支持“工单文本 + 故障时间”的建模路线 [3]。

8.2 市场支撑

市场上已经存在类似思想的资产预测性维护产品。IBM Maximo Predict 可输出资产失效概率、预测失效日期、失效模式概率，并支持通过工作队列追踪高故障概率资产，用于维护计划和检查工单 [4][5][6]。这说明“风险窗口 + 高风险资产队列 + 维护计划”的产品形态是存在工程价值的。

公共交通领域也已有 AI 预测性维护探索。Cubic Transportation Systems 与相关研究团队将 AI 用于公共交通票务设备维护，强调利用维护日志和事件报告预测所需备件、减少工程师无效上门和缩短停机时间 [7][8]。这与本项目“地铁 AFC 闸机工单驱动预测 + 维修建议 Agent”的方向具有一致性。

九、创新性建议

项目创新点不宜写成“发明全新算法”，而应写成面向具体场景和数据约束的系统化创新。

创新点	具体表述
无传感器场景下的工单驱动预测	面向缺少实时传感器数据的 AFC 闸机场景，利用维修工单构建设备复发风险模型。
风险窗口替代单点日期预测	以 7/30/90 天风险和高风险时间窗口指导巡检，避免工单日期噪声导致的过度精确。
故障文本标准化与复发建模结合	将短文本故障描述归一为标准现象，再与历史复发序列结合建模。
模型结果到维修建议的 Agent 化转化	不仅输出概率，还生成原因解释、检查方向、备件建议和巡检优先级。
轻量化行业落地系统	不同于大型 EAM/CMMS，本项目可面向单线路、单子系统快速部署和验证。

十、后续实施计划

建议按“先做可解释基线，再逐步增加复杂度”的方式推进，避免一开始堆叠复杂深度学习模型。

阶段	工作内容	验收结果
第 1 阶段：数据理解	完成字段说明、缺失率统计、故障描述频次、设备故障次数分布、复发间隔分布。	一份数据质量分析报告。
第 2 阶段：故障现象归类	用规则词典 + 文本清洗将 description 标准化为 10-20 类故障现象。	标准故障类型字段。
第 3 阶段：复发标签构造	构造 7/30/90 天内是否复发标签，按时间切分训练集和测试集。	可训练样本表。
第 4 阶段：风险模型	训练逻辑回归、随机森林、LightGBM/CatBoost，比较 AUC、召回率、Top-K 命中率。	风险预测模型和评估表。
第 5 阶段：巡检优先级	把风险概率、历史复发频率、故障严重程度组合成排序评分。	高风险设备 Top N 清单。
第 6 阶段：Agent 系统	接入模型输出、历史案例检索、维修规则库，生成自然语言建议。	可演示的智能维修建议系统。

十一、可直接用于汇报的最终表述

本项目不将“精确预测某一天必然故障”作为核心目标。由于地铁 AFC 闸机故障工单属于事件驱动型数据，其记录时间不仅受设备真实故障发生时间影响，还受到人工发现、报修流程、派工安排、维修记录习惯等因素影响，因此工单日期不能完全等价于设备物理故障发生时刻。

基于这一数据特点，本项目采用多时间窗口复发风险建模方式，分别评估闸机在未来 7 天、30 天和 90 天内再次产生故障工单的概率，并结合历史复发间隔估计高风险时间窗口。系统进一步根据风险概率、

故障现象、车站聚集性和历史复发频率生成巡检优先级，辅助运维人员决定“先查哪台设备、准备什么备件、重点检查哪些模块”。

因此，项目的实际价值不是声称“预测闸机哪一天一定会坏”，而是帮助地铁运维从被动报修转向主动巡检，在有限人力和备件条件下优先处理最可能近期复发的设备。

十二、参考资料

[1] Genevieve Moat, Shirley Coleman. Survival Analysis and Predictive Maintenance Models for Non-sensored Assets in Facilities Management. <https://eprints.ncl.ac.uk/fulltext.aspx?url=279830%2F8BFE1B5D-8CAA-46CF-BB60-028EA96B6519.pdf>

[2] H. Burak Gunay, Weiming Shen, Chunsheng Yang. Text-mining building maintenance work orders for component fault frequency. <https://www.tandfonline.com/doi/abs/10.1080/09613218.2018.1459004>

[3] K. Arif-Uz-Zaman et al. Extracting failure time data from industrial maintenance records using text mining. <https://www.sciencedirect.com/science/article/abs/pii/S1474034616301380>

[4] IBM Documentation. Maximo Predict overview. <https://www.ibm.com/docs/en/mhmpmh-and-p-u/cd?topic=overview-maximo-predict>

[5] IBM Documentation. Using predictive model output data. <https://www.ibm.com/docs/en/ma-pmis?topic=data-using-predictive-model-output>

[6] IBM Documentation. Assets and locations: failure probability and prediction window. <https://www.ibm.com/docs/en/mhmpmh-and-p-u/cd?topic=using-assets-locations>

[7] Cubic Transportation Systems. AI-powered predictive maintenance in public transportation report. <https://go.cubic.com/transportation-ai-unlocks-predictive-maintenance-in-public-transportation-report>

[8] AIDA Lab. Keeping Transit Networks Moving: AI-powered predictive maintenance transforms public transport. <https://www.aidalab.co.uk/researcharticles/keeping-transit-networks-moving-how-ai-powered-predictive-maintenance-transforms-public-transport>

附录：建议优先补充的数据字段

补充字段	为什么重要
维修措施	判断上一次是临时处理还是彻底维修，解释短期复发。
更换部件	将“故障现象”进一步映射到“真实部件根因”。
维修关闭时间/停机时长	衡量故障严重度和运维响应效率。
设备安装日期/使用年限	构造设备老化特征。
客流量/交易量/闸门开合次数	衡量设备使用强度和机械磨损。
系统日志/错误码	提升“暂停服务、死机、通信中断”等问题的根因判断能力。
备件消耗记录	支持维修建议和备件计划。